Big Data – studia stacjonarne 2026/27

Projekt 1 – zespoły dwuosobowe

Cel projektu:

Przygotowanie aplikacji, która pobiera dane z wybranego źródła, zapisuje je, przetwarza, analizuje statystycznie i prezentuje wyniki. Preferowanym językiem implementacji jest Python. Wymagania na wyższe oceny obejmują wymagania z niższych progów. (min. 5 GB danych po wypakowaniu)

Wymagania na ocenę 3,0

- Wybierz problem i udokumentowane źródło danych: otwarty zbiór, API albo stronę internetową, z której można pobierać dane.
- Napisz aplikację importującą dane do lokalnej bazy MongoDB.
- Zastosuj podstawowe sprawdzanie i czyszczenie danych oraz wykonaj co najmniej trzy sensowne analizy statystyczne.
- Przedstaw wyniki w prostej wizualizacji lub w czytelnych zestawieniach.
- Umieść na platformie Delta kod, dane lub instrukcję ich pobrania oraz sprawozdanie. Prezentacja projektu nie jest wymagana.

Wymagania na ocenę 4,0

- Spełnij wymagania na ocenę 3,0.
- W projekcie wykorzystaj przynajmniej dwie bazy: lokalną lub umieszczoną na prywatnym serwerze, oraz udostępnioną w ramach darmowej chmury MongoDB.
- Zaimplementuj ponowne uruchomienie importu tak, aby nie powodowało niekontrolowanego powielania danych.
- Dane do minimum jednej z baz mają być pozyskiwane na zasadzie web scrapping'u.
- Zaprezentuj projekt i omów przepływ danych oraz wyniki analizy.

Wymagania na ocenę 5,0

- Spełnij wymagania na ocenę 4,0.
- Zapisuj główny zbiór danych w **HDFS**.
- Wykorzystaj **Hadoop MapReduce** do przetworzenia danych i wykonania analizy statystycznej. W przypadku implementacji w Pythonie można użyć Hadoop Streaming.
- Zapisuj w MongoDB wyniki analizy, agregaty lub metadane. Główna część zbioru danych ma być przechowywana w HDFS(dane do HDFS mogą pochodzić z raportów zapisanych w postaci plików czy otwartych zbiorów danych).
- Zapewnij szyfrowane połączenie z bazami MongoDB i uwierzytelnienie. W ramach projektu zaimplementuj prosty mechanizm wizualizacji statystyk lub wykorzystaj funkcjonalności MongoDB Compass.
- Zaprezentuj działanie aplikacji, sposób przetwarzania w Hadoop oraz wyniki analizy.

Przygotuj obszerne sprawozdanie napisane poprawną polszczyzną zawierające:

- opis problemu wraz ze szczegółowym opisem danych,
- szczegółowy opis implementacji,
- uruchomienie i przedstawienie jej możliwości.

Do projektu należy załączyć dane, kody oraz sprawozdanie.

Termin oddania: 26.11.2026. Po tym terminie projekt nie będzie przyjmowany.

mgr inż. Maryna Łukaczyk
Wydział Informatyki i Matematyki Politechniki Krakowskiej